

XAI 可解释性研究与设计流程图

从问题发现到解释生成，再到技术验证与用户验证。适合作为文献综述中的“综合流程框架”。

A4 / 1 of 2

场景与用户层 模型与 XAI 技术层 解释评估层 非标准流程中常见风险

1 定义应用场景

先判断 AI 用在什么任务中：医疗、教育、机器人、金融、环境监测、具身智能体等。场景决定风险等级与解释深度。

2 识别目标用户

解释不是给“所有人”看的。开发者、领域专家、普通用户、学生、教师、监管者需要的解释粒度不同。

3 发现解释需求

通过访谈、任务观察、错误案例、信任断点分析，确认用户在什么时候需要解释，以及需要全局解释还是单次预测解释。

4 定义解释对象

决定解释什么：数据来源与偏差、模型整体逻辑、某次预测原因、机器人行为意图、学习者错误原因等。

5 判断数据与模型类型

表格、图像、文本、时间序列、传感器和动作数据适合不同方法。模型是白箱、树模型、深度网络，也会影响方法选择。

6 选择 XAI 方法

可选内在可解释模型，也可选事后解释方法：LIME、SHAP、Tree-SHAP、TreeInterpreter、Grad-CAM、反事实解释等。

7 生成解释数据

输出通常是中间数据：特征贡献、重要性排序、相关系数、决策路径、热力图、反事实样本、失败原因标签。

8 转译成人能理解的表达

将解释数据转成图表、表格、短文本、对话、语音、动作提示或教学反馈。LLM 可承担“文字化解释层”。

9 技术验证

检查解释是否忠实、稳定、一致、鲁棒，计算是否足够快。重点是：解释有没有真实反映模型行为。

10 用户验证与迭代

检查用户是否更理解、适当信任、完成任务更快、错误更少。若解释造成过度信任或干扰任务，需要重新设计。

Ali 等综述支撑

数据可解释性、模型可解释性、事后可解释性、解释评估四轴。

NIST 支撑

解释应提供理由、能被用户理解、能正确反映系统过程。

DARPA 支撑

XAI 目标是让人理解、适当信任并有效管理 AI 伙伴。

SHAP+LLM 论文支撑

SHAP 图转表格，再输入 LLM 生成面向非技术用户的文字解释。

关键判断：这不是一个被全领域强制采用的标准流程，而是从 XAI 分类框架、可解释性原则、SHAP 方法和人机交互评估中综合出的“可验证 workflow”。

方法选择、解释输出与评估路径

把“用什么方法解释”和“怎么证明解释有效”放在同一页，避免只做漂亮说明而缺少验证。

A4 / 2 of 2

1. 按数据与任务选择方法

数据/任务	常见 XAI 方法	输出形式
表格数据 风险预测、分类、评分	SHAP、LIME、特征重要性、反事实解释、决策树	特征贡献、正负影响、重要性排序、如果改变某项会怎样
树模型 XGBoost、随机森林、决策树	Tree-SHAP、TreeInterpreter、路径解释	每个分裂条件如何推动预测，哪些特征贡献最大
图像模型 识别、检测、诊断	Grad-CAM、显著性图、遮挡测试	模型关注的图像区域、热力图、关键视觉证据
文本模型 分类、推荐、审核	关键词归因、token 贡献、反事实文本	哪些词句影响判断，替换哪些词会改变结果
机器人/具身智能体	动作意图解释、失败原因解释、社交线索解释	语言、动作、箭头、路径、提示音、状态说明
教育与培训	开放学习者模型、错误类型解释、教学反馈	知识点掌握情况、误解位置、下一步练习建议

LLM 在流程中的位置

LLM 通常不直接替代 XAI 算法，而是把 XAI 输出的结构化结果转成更自然的文字、问答或教学反馈。它适合做“表达层”，但需要用原始解释数据约束，避免自由发挥。

表格转解释 摘要生成 多层次说明 面向非专家改写

2. 如何评估“解释更好”

技术评估：解释本身准不准

适合证明解释不是随便生成的。常看忠实度、稳定性、一致性、鲁棒性、计算时间、重要特征删除后的模型变化。

faithfulness 忠实度 stability 稳定性 Kendall's Tau RBO
运行时间

用户评估：解释对人有没有用

适合证明解释真的改善理解和决策。常用问卷、理解测验、任务完成时间、错误率、信任量表、访谈。

理解度 适当信任 任务效率 错误率 访谈反馈

SHAP + LLM 示例链路

模型预测 → SHAP 全局图 → 提取特征重要性和相关系数 → 表格化 → ChatGPT API → 100 词解释。

机器人比较示例链路

抓取失败模型 → LIME / Tree-SHAP / TreeInterpreter → 比较特征排序一致性和运行速度。

没有流程时容易出现的问题

只做技术指标但用户看不懂；只做漂亮可视化但不忠实于模型；只让 LLM 解释却不检查事实；只测信任提升却造成过度信任；不同研究指标不一致，难以比较。

最稳妥的研究表述

“XAI 目前没有统一标准流程，但可以形成场景驱动的综合流程：先定义用户与解释需求，再选择数据、模型和 XAI 方法，最后同时进行技术评估和用户评估。”